Regresión Notas PAU

Javier Ribal del Río Pau Minguet Micó

Table of contents

1 Información previa **2**

2 Estructura de la base de datos (SQLite) / Descripción del *dataframe* **2**
2.1 Resumen rápido de la estructura de datos . . . 2
2.2 `subjects` . . . 3
2.3 `marks` . . . 4
2.4 `high_school_types` . . . 4
2.5 `provinces` . . . 4
2.6 `regions` . . . 5
2.7 `municipalities` . . . 5
2.8 `high_schools` . . . 6
2.9 `high_school_marks` . . . 6
2.10 `global_results` . . . 7
2.11 `high_school_types_results` . . . 8

3 Modelos de Regresión **9**
3.1 Modelo 1 . . . 9
3.1.1 Diagrama de Dispersión . . . 10
3.2 Modelo 2 . . . 11
3.3 Modelo 3 . . . 12
3.4 Matriz de correlación de algunas de las variables . . . 13
3.5 Modelo 4 . . . 14
3.6 Modelo 4 Estandarizado . . . 14
3.7 Modelo 5 . . . 15
3.8 Modelo 6 . . . 16

4 Comprobaciones **17**
4.1 Análisis de los gráficos . . . 18
4.2 Evidencia visual . . . 19

1 Información previa

Página web: https://ribal21-notas-pau-cv.share.connect.posit.cloud

Código (repositorio): https://github.com/JavierRibaldelRio/Notas-PAU-CV

Cargar librerías y base de datos

2 Estructura de la base de datos (SQLite) / Descripción del *dataframe*

Los datos utilizados en este proyecto se almacenan en una **base de datos relacional SQLite**. SQLite es un motor de base de datos ligero basado en archivos que no requiere servidor, lo que lo hace especialmente adecuado para proyectos de análisis de datos, investigación reproducible y su integración con herramientas como **R**.

La base de datos contiene información relacionada con los **resultados de las pruebas de acceso a la universidad (PAU)**, las **asignaturas**, los **centros educativos** y su **contexto territorial** (municipios, provincias y regiones).
La estructura sigue un diseño relacional normalizado donde las entidades se separan en distintas tablas y se conectan mediante **claves foráneas (foreign keys)**.

La base de datos se ha generado extrayendo datos de los PDF con las estadísiticas oficiales de la PAU, los datos relativos a los centros de la guia de centros de la consellería de educación (datos ya no disponibles). Los datos cartográficos y territoriales provienen del CNIG o del Instituto Cartográfico Valenciano

2.1 Resumen rápido de la estructura de datos

- **Base de datos:** SQLite relacional diseñada para analizar los **resultados de la PAU** en la Comunidad Valenciana.
- **Nivel territorial:**
  - `regions` → comarcas o regiones.
  - `provinces` → provincias.
  - `municipalities` → municipios.
  - Permiten geolocalizar los centros educativos.
- **Centros educativos:**
  - `high_schools` → información administrativa y geográfica de cada centro.
  - `high_school_types` → clasificación del centro (público, concertado, privado).

- **Resultados por centro:**
  - `high_school_marks` → resultados agregados de la PAU por **centro, año y convocatoria**.
  - Incluye:
    * número de estudiantes,
    * porcentaje de aprobados,
    * medias y desviaciones estándar,
    * comparación entre **nota de bachillerato y nota de PAU**.
- **Resultados por asignatura:**
  - `subjects` → catálogo de asignaturas.
  - `marks` → resultados agregados por **asignatura, año y convocatoria**.
- **Resultados agregados del sistema:**
  - `global_results` → estadísticas globales del sistema educativo para cada año y convocatoria.
  - `high_school_types_results` → resultados agregados **por tipo de centro**.
- **Nivel de análisis posible:**
  - por **asignatura**,
  - por **centro educativo**,
  - por **tipo de centro**,
  - por **territorio**,
  - y a **nivel global del sistema educativo**.

2.2 `subjects`

Esta tabla contiene el catálogo de **asignaturas evaluadas en la PAU**.

Campo	Descripción
`id`	Identificador único de la asignatura (clave primaria).
`code`	Código oficial de la asignatura (máximo 6 caracteres).
`name`	Nombre oficial de la asignatura.
`other_names`	Otros nombres o denominaciones alternativas de la asignatura.

2.3 `marks`

Esta tabla almacena **estadísticas agregadas de resultados por asignatura**, año y convocatoria.

Campo	Descripción
`id`	Clave primaria.
`subject_id`	Identificador de la asignatura (`subjects.id`).
`year`	Año de la convocatoria.
`call`	Convocatoria del examen.
`enrolled_total`	Número total de estudiantes matriculados.
`candidates`	Número de estudiantes que finalmente se presentan al examen.
`pass`	Número de estudiantes que aprueban.
`pass_percentatge`	Porcentaje de aprobados.
`average`	Nota media obtenida.
`standard_dev`	Desviación estándar de las calificaciones.
`candidates_compulsory`	Número de candidatos en la fase obligatoria.
`pass_compulsory`	Número de aprobados en la fase obligatoria.
`candidates_optional`	Número de candidatos en la fase opcional.
`pass_optional`	Número de aprobados en la fase opcional.
`coefficient_variation`	Coeficiente de variación de las calificaciones.

2.4 `high_school_types`

Tabla que define los **tipos de centros educativos**.

Campo	Descripción
`id`	Identificador del tipo de centro (clave primaria).
`type`	Nombre del tipo de centro (por ejemplo, público, concertado o privado).

2.5 `provinces`

Tabla que contiene las **provincias**.

Campo	Descripción
`id`	Identificador de la provincia.
`name`	Nombre de la provincia.
`provincial_capital`	Municipio que actúa como capital provincial.

2.6 `regions`

Tabla que contiene las **regiones o comarcas**.

Campo	Descripción
`id`	Identificador de la región.
`name`	Nombre de la región.
`province`	Provincia a la que pertenece.
`region_code`	Código identificador de la región.

2.7 `municipalities`

Tabla que almacena los **municipios**.

Campo	Descripción
`id`	Identificador del municipio.
`ine_code`	Código oficial del INE.
`name`	Nombre del municipio.
`other_names`	Otros nombres o denominaciones del municipio.
`region`	Región o comarca a la que pertenece.
`province`	Provincia a la que pertenece.

2.8 `high_schools`

Esta tabla contiene información sobre los **centros de educación secundaria**.

Campo	Descripción
`id`	Identificador único del centro.
`code`	Código identificador del centro.
`name`	Nombre del centro educativo.
`type_id`	Tipo de centro (`high_school_types.id`).
`cif`	CIF o identificador fiscal del centro.
`address`	Dirección del centro.
`postal_code`	Código postal.
`municipality_id`	Municipio donde se encuentra el centro.
`latitude`	Latitud geográfica.
`longitude`	Longitud geográfica.
`email`	Correo electrónico del centro.
`phone_number`	Teléfono de contacto.
`fax`	Número de fax.
`website`	Página web del centro.
`owner`	Titularidad del centro.
`image`	Imagen asociada al centro (almacenada como BLOB).

2.9 `high_school_marks`

Esta tabla recoge **resultados agregados de la PAU a nivel de centro educativo**.

Campo	Descripción
`id`	Clave primaria.
`high_school_id`	Centro educativo al que corresponden los datos.
`year`	Año de la convocatoria.
`call`	Convocatoria del examen.
`enrolled_total`	Estudiantes matriculados.
`candidates`	Estudiantes presentados.
`pass`	Estudiantes aprobados.
`pass_percentatge`	Porcentaje de aprobados.
`average_bach`	Nota media del bachillerato.
`standard_dev_bach`	Desviación estándar del bachillerato.
`average_compulsory_pau`	Nota media de la fase obligatoria de la PAU.

Campo	Descripción
`standard_dev_pau`	Desviación estándar de la fase obligatoria.
`diference_average_bach_pau`	Diferencia entre la media de bachillerato y la media de la PAU.
`coeff_variation_bach`	Coeficiente de variación del bachillerato.
`coeff_variation_pau`	Coeficiente de variación de la PAU.

2.10 `global_results`

Esta tabla recoge **estadísticas agregadas del conjunto del sistema educativo** para cada año y convocatoria.

Campo	Descripción
`id`	Identificador del registro (clave primaria).
`year`	Año de la convocatoria.
`call`	Convocatoria del examen.
`enrolled`	Número total de estudiantes matriculados.
`candidates`	Número total de estudiantes presentados.
`pass`	Número total de estudiantes aprobados.
`pass_percentage`	Porcentaje total de aprobados.
`candidates_m`	Número de candidatos hombres.
`candidates_w`	Número de candidatos mujeres.
`pass_percentage_m`	Porcentaje de aprobados hombres.
`pass_percentage_w`	Porcentaje de aprobados mujeres.
`average_bach`	Nota media de bachillerato.
`standard_dev_bach`	Desviación estándar de bachillerato.
`average_pau`	Nota media de la PAU.
`standard_dev_pau`	Desviación estándar de la PAU.
`average_nau`	Nota media de acceso a la universidad (NAU).
`standard_dev_nau`	Desviación estándar de la NAU.
`final_average_pass`	Nota media final de los estudiantes aprobados.
`exclusive_candidates_general`	Candidatos que solo se presentan a la fase general.
`exclusive_candidates_especific`	Candidatos que solo se presentan a la fase específica.
`candidates_both`	Candidatos que se presentan a ambas fases.
`fp_candidates_especific`	Estudiantes procedentes de formación profesional que se presentan a la fase específica.

2.11 `high_school_types_results`

Esta tabla contiene **resultados agregados por tipo de centro educativo**.

Campo	Descripción
`id`	Identificador del registro.
`year`	Año de la convocatoria.
`call`	Convocatoria del examen.
`type_id`	Tipo de centro educativo (`high_school_types.id`).
`enrolled`	Estudiantes matriculados.
`candidates`	Estudiantes presentados.
`pass`	Estudiantes aprobados.
`pass_percentage`	Porcentaje de aprobados.
`candidates_m`	Candidatos hombres.
`candidates_w`	Candidatos mujeres.
`pass_percentage_m`	Porcentaje de aprobados hombres.
`pass_percentage_w`	Porcentaje de aprobados mujeres.
`average_bach`	Nota media de bachillerato.
`standard_dev_bach`	Desviación estándar de bachillerato.
`average_pau`	Nota media de PAU.
`standard_dev_pau`	Desviación estándar de PAU.
`average_nau`	Nota media NAU.
`standard_dev_nau`	Desviación estándar NAU.
`final_average_pass`	Nota media final de aprobados.
`exclusive_candidates_general`	Candidatos solo en fase general.
`exclusive_candidates_especific`	Candidatos solo en fase específica.
`candidates_both`	Candidatos en ambas fases.
`fp_candidates_especific`	Candidatos de FP en fase específica.

Esta estructura permite analizar los resultados de la PAU a distintos niveles:

- por **asignatura**,
- por **centro educativo**,
- por **tipo de centro**,
- por **territorio (municipio, provincia o región)**,
- y a **nivel global del sistema educativo**.

3 Modelos de Regresión

La variable a predecir es: la **nota media de la fase obligatoria de la PAU por centro**

3.1 Modelo 1

Única variable explicativa nota media del centro en bachillerato

$$\mathrm{PAU_i t} = \beta_0 + \beta_1 \mathrm{Bach_{it}} + \epsilon_{it}$$

```
# realizar la regresión
data1 <- dbGetQuery(
  con,
  "SELECT * FROM high_school_marks JOIN high_schools ON  high_school_marks.high_school_id = h
)

data1 <- data1[, !duplicated(names(data1))]

modelo_1 <- data1 |>
  lm(average_compulsory_pau ~ average_bach, data = _)

summary(modelo_1) # visualización con R
```

```
Call:
lm(formula = average_compulsory_pau ~ average_bach, data = data1)

Residuals:
    Min      1Q  Median      3Q     Max 
-3.2440 -0.2665  0.0066  0.2934  1.4624 

Coefficients:
             Estimate Std. Error t value Pr(>|t|)    
(Intercept)   0.40601    0.08906   4.559 5.24e-06 ***
average_bach  0.79663    0.01207  65.974  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4333 on 6782 degrees of freedom
  (9 observations deleted due to missingness)
Multiple R-squared:  0.3909,	Adjusted R-squared:  0.3908 
```

```
F-statistic:  4353 on 1 and 6782 DF,  p-value: < 2.2e-16
```

```r
tidy(modelo_1)
```

```
# A tibble: 2 x 5
  term         estimate std.error statistic    p.value
  <chr>           <dbl>     <dbl>     <dbl>      <dbl>
1 (Intercept)     0.406    0.0891      4.56 0.00000524
2 average_bach    0.797    0.0121     66.0  0
```

```r
glance(modelo_1)
```

```
# A tibble: 1 x 12
  r.squared adj.r.squared sigma statistic p.value    df logLik   AIC   BIC
      <dbl>         <dbl> <dbl>     <dbl>   <dbl> <dbl>  <dbl> <dbl> <dbl>
1     0.391         0.391 0.433     4353.       0     1 -3952. 7909. 7930.
# i 3 more variables: deviance <dbl>, df.residual <int>, nobs <int>
```

1. El coeficiente de `average_bach` es de 0.79663 lo que quiere decir que si la media de bachillerato aumenta 1 punto la nota de la pau lo hace solo en el coeficiente previo
2. R-squared: 0.3909, no se acerca a 1 por lo que podría ser un modelo mejorable
3. Mirando el p-valor es inferior a 0.005 por lo que, como era esperable es estadísticamente significativo.

3.1.1 Diagrama de Dispersión

```r
data1|>
  ggplot(aes(y=average_compulsory_pau, x=average_bach)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = TRUE) +
  theme_bw()
```

```
Warning: Removed 9 rows containing non-finite outside the scale range
(`stat_smooth()`).
```

```
Warning: Removed 9 rows containing missing values or values outside the scale range
(`geom_point()`).
```

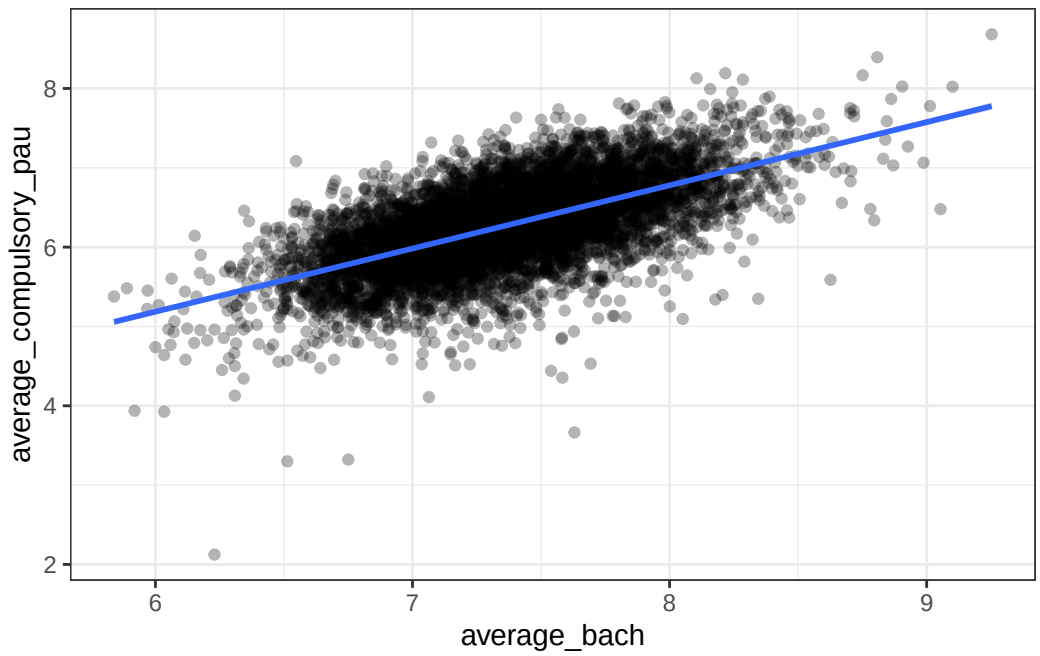

3.2 Modelo 2

$$\mathrm{PAU_i t} = \beta_0 + \beta_1 \mathrm{Bach_mean_{it}} + \beta_2 \mathrm{Bach_sd_{it}} + \epsilon_{it}$$

Incorporamos la desviación de la nota media de bachillerato a nuestra regresión.

```
modelo_2 <- data1 |>
  lm(average_compulsory_pau ~ average_bach + standard_dev_bach, data = _)

tidy(modelo_2)
```

```
# A tibble: 3 x 5
  term              estimate std.error statistic  p.value
  <chr>                <dbl>     <dbl>     <dbl>    <dbl>
1 (Intercept)          0.300    0.0902      3.32 9.02e- 4
2 average_bach         0.777    0.0124     62.6  0
3 standard_dev_bach    0.228    0.0344      6.63 3.55e-11
```

```
glance(modelo_2)
```

```
# A tibble: 1 x 12
  r.squared adj.r.squared sigma statistic p.value    df logLik   AIC   BIC
      <dbl>         <dbl> <dbl>     <dbl>   <dbl> <dbl>  <dbl> <dbl> <dbl>
1     0.395         0.395 0.432     2212.       0     2 -3930. 7867. 7895.
# i 3 more variables: deviance <dbl>, df.residual <int>, nobs <int>
```

1. El valor de $\beta_2 = 0.228$
2. R^2 aumenta en 0.005 (=0.395)

ChatGPT destaca el hecho de que sea positivo, porque el esperaba que fuese negativo. ??

3.3 Modelo 3

Incorporamos el factor de régimen. Lo introducimos como *variables binarias* es decir dos variable y hacer combinaciones. Por ejemplo, 00 → público, 01 → privado, 10 → concertado.

¿Qué pasa con el p-valor del público?

```r
modelo_3 <-  data1 |>
  mutate(regime = as.factor(type_id)) |>
    lm(average_compulsory_pau ~ average_bach + standard_dev_bach + regime, data = _)
tidy(modelo_3)
```

```
# A tibble: 5 x 5
  term              estimate std.error statistic       p.value
  <chr>                <dbl>     <dbl>     <dbl>         <dbl>
1 (Intercept)         0.351     0.0911      3.86 0.000116
2 average_bach        0.771     0.0125     61.5  0
3 standard_dev_bach   0.209     0.0350      5.96 0.00000000268
4 regime1             0.0443    0.0128      3.45 0.000571
5 regime2             0.0574    0.0239      2.40 0.0164
```

```r
glance(modelo_3)
```

```
# A tibble: 1 x 12
  r.squared adj.r.squared sigma statistic p.value    df logLik   AIC   BIC
      <dbl>         <dbl> <dbl>     <dbl>   <dbl> <dbl>  <dbl> <dbl> <dbl>
1     0.396         0.396 0.432     1112.       0     4 -3922. 7856. 7897.
# i 3 more variables: deviance <dbl>, df.residual <int>, nobs <int>
```

1. Aparecen dos nuevos p-valor para regimen 1 y 2, los dos son significactivos, aunque el segundo en menor medida que el primero

2. La R^2 no aumenta casi solo en 0.001

   El régimen del centro está asociado de forma estadísticamente significativa con la nota media de la PAU, una vez controladas la media y la dispersión de bachillerato. Sin embargo, su contribución adicional al poder explicativo global del modelo es reducida.

3.4 Matriz de correlación de algunas de las variables

```r
data1 |>
  select(
    average_compulsory_pau,
    average_bach,
    standard_dev_bach,
    enrolled_total,
    candidates,
    pass
  ) |>
  cor(use ="complete.obs")
```

```
                      average_compulsory_pau average_bach standard_dev_bach
average_compulsory_pau             1.00000000   0.62522499         0.2125813
average_bach                       0.62522499   1.00000000         0.2427856
standard_dev_bach                  0.21258133   0.24278560         1.0000000
enrolled_total                     0.07182699   0.01059415         0.2183525
candidates                         0.07289764   0.01051608         0.2186717
pass                               0.12317328   0.03355176         0.2206843
                      enrolled_total candidates       pass
average_compulsory_pau     0.07182699 0.07289764 0.12317328
average_bach               0.01059415 0.01051608 0.03355176
standard_dev_bach          0.21835247 0.21867165 0.22068431
enrolled_total             1.00000000 0.99981806 0.99566210
candidates                 0.99981806 1.00000000 0.99606242
pass                       0.99566210 0.99606242 1.00000000
```

A pesar de que candidatos no presenta mucha relación con average_compulsory_pau la podemos introducir en el model para ver si es estadísticamente significativa

3.5 Modelo 4

Introducimos el número de candidatos

```
modelo_4 <- data1 |>
  mutate(regime = as.factor(type_id)) |>
  lm(
    average_compulsory_pau ~ average_bach + standard_dev_bach + regime + candidates,
    data = _
  )

tidy(modelo_4)
```

```
# A tibble: 6 x 5
  term              estimate std.error statistic       p.value
  <chr>                <dbl>     <dbl>     <dbl>         <dbl>
1 (Intercept)        0.328    0.0910        3.60 0.000315
2 average_bach       0.773    0.0125       61.8  0
3 standard_dev_bach  0.168    0.0357        4.72 0.00000239
4 regime1            0.0374   0.0129        2.91 0.00367
5 regime2            0.0758   0.0241        3.15 0.00164
6 candidates         0.00111  0.000193      5.76 0.00000000879
```

```
glance(modelo_4)
```

```
# A tibble: 1 x 12
  r.squared adj.r.squared sigma statistic p.value    df logLik   AIC   BIC
      <dbl>         <dbl> <dbl>     <dbl>   <dbl> <dbl>  <dbl> <dbl> <dbl>
1     0.399         0.399 0.430      901.       0     5 -3905. 7825. 7872.
# i 3 more variables: deviance <dbl>, df.residual <int>, nobs <int>
```

Los candidatos son ahora la segunda variable más significativa solo por detrás de la media de bachillerato

El valor de R^2 asciende hasta 0.399

3.6 Modelo 4 Estandarizado

Escalando las variables.

$$z_i = \frac{x_i - \bar{x}}{s_x}$$

```
modelo_4_std <- data1 |>
  mutate(regime = as.factor(type_id)) |>
  select(average_compulsory_pau, average_bach, standard_dev_bach, regime, candidates) |>
  drop_na() |>
  mutate(
    average_compulsory_pau = as.numeric(scale(average_compulsory_pau)),
    average_bach = as.numeric(scale(average_bach)),
    standard_dev_bach = as.numeric(scale(standard_dev_bach)),
    candidates = as.numeric(scale(candidates))
  ) |>
  lm(
    average_compulsory_pau ~ average_bach + standard_dev_bach + regime + candidates,
    data = _
  )

tidy(modelo_4_std)
```

```
# A tibble: 6 x 5
  term              estimate std.error statistic       p.value
  <chr>                <dbl>     <dbl>     <dbl>         <dbl>
1 (Intercept)        -0.0228   0.0112      -2.03 0.0422
2 average_bach        0.607    0.00981     61.8  0
3 standard_dev_bach   0.0477   0.0101       4.72 0.00000239
4 regime1             0.0674   0.0232       2.91 0.00367
5 regime2             0.137    0.0434       3.15 0.00164
6 candidates          0.0565   0.00980      5.76 0.00000000879
```

3.7 Modelo 5

Introducción del segundo grado en la nota media de bachillerato.

```
modelo_5 <- data1 |>
  mutate(regime = as.factor(type_id)) |>
  lm(
    average_compulsory_pau ~ average_bach + I(average_bach^2) +
      standard_dev_bach + regime + candidates,
    data = _
  )
```

```r
tidy(modelo_5)
```

```
# A tibble: 7 x 5
  term               estimate std.error statistic      p.value
  <chr>                 <dbl>     <dbl>     <dbl>        <dbl>
1 (Intercept)        -1.00     1.12        -0.889 0.374
2 average_bach        1.14     0.307        3.70  0.000218
3 I(average_bach^2) -0.0245    0.0207      -1.19  0.236
4 standard_dev_bach  0.153     0.0379       4.05  0.0000527
5 regime1            0.0398    0.0130       3.06  0.00226
6 regime2            0.0807    0.0244       3.30  0.000959
7 candidates         0.00111   0.000194     5.72  0.0000000111
```

```r
glance(modelo_5)
```

```
# A tibble: 1 x 12
  r.squared adj.r.squared sigma statistic p.value    df logLik   AIC   BIC
      <dbl>         <dbl> <dbl>     <dbl>   <dbl> <dbl>  <dbl> <dbl> <dbl>
1     0.399         0.399 0.430      751.       0     6 -3905. 7825. 7880.
# i 3 more variables: deviance <dbl>, df.residual <int>, nobs <int>
```

No es significativo

3.8 Modelo 6

Introducimos el factor año y el factor centro

```r
modelo_6 <- data1 |>
  mutate(
    regime = as.factor(type_id),
    year = as.factor(year),
    center = as.factor(high_school_id))|>
  lm(
    average_compulsory_pau ~ average_bach + standard_dev_bach + regime + candidates + year +
    data = _
  )

tidy(modelo_6)
```

```
# A tibble: 496 x 5
   term              estimate std.error statistic   p.value
   <chr>                <dbl>     <dbl>     <dbl>     <dbl>
 1 (Intercept)        1.36     0.168         8.07 8.43e- 16
 2 average_bach       0.671    0.0166       40.5  8.03e-319
 3 standard_dev_bach  0.0520   0.0315        1.65 9.81e-  2
 4 regime1           -0.170    0.162        -1.05 2.93e-  1
 5 regime2           -0.339    0.264        -1.29 1.98e-  1
 6 candidates        -0.00254  0.000415     -6.14 8.95e- 10
 7 year2011           0.0630   0.0222        2.83 4.67e-  3
 8 year2012           0.0433   0.0222        1.95 5.09e-  2
 9 year2013          -0.0270   0.0222       -1.22 2.23e-  1
10 year2014           0.137    0.0223        6.14 8.78e- 10
# i 486 more rows
```

```r
glance(modelo_6)
```

```
# A tibble: 1 x 12
  r.squared adj.r.squared sigma statistic p.value    df logLik   AIC   BIC
      <dbl>         <dbl> <dbl>     <dbl>   <dbl> <dbl>  <dbl> <dbl> <dbl>
1     0.676         0.651 0.328      26.7       0   493 -1807. 4603. 7980.
# i 3 more variables: deviance <dbl>, df.residual <int>, nobs <int>
```

¿Tiene sentido introducir el factor centro? ¿Nos limita la posibilidad de introducir el factor renta?

¿Qué mas factores podemos introducir?

- Renta
- Datos electorales
- Nivel educativo medio de la zona
- Valenciano/Castellano

Problema de obtención temporal de los distintos datos

4 Comprobaciones

Para hacer todas las comprobaciones ahora nos centraremos en el `modelo_4`. Primero vamos a hacer unos gráficos de diagnóstico.

```r
par(mfrow = c(2, 2))
plot(modelo_4)
```

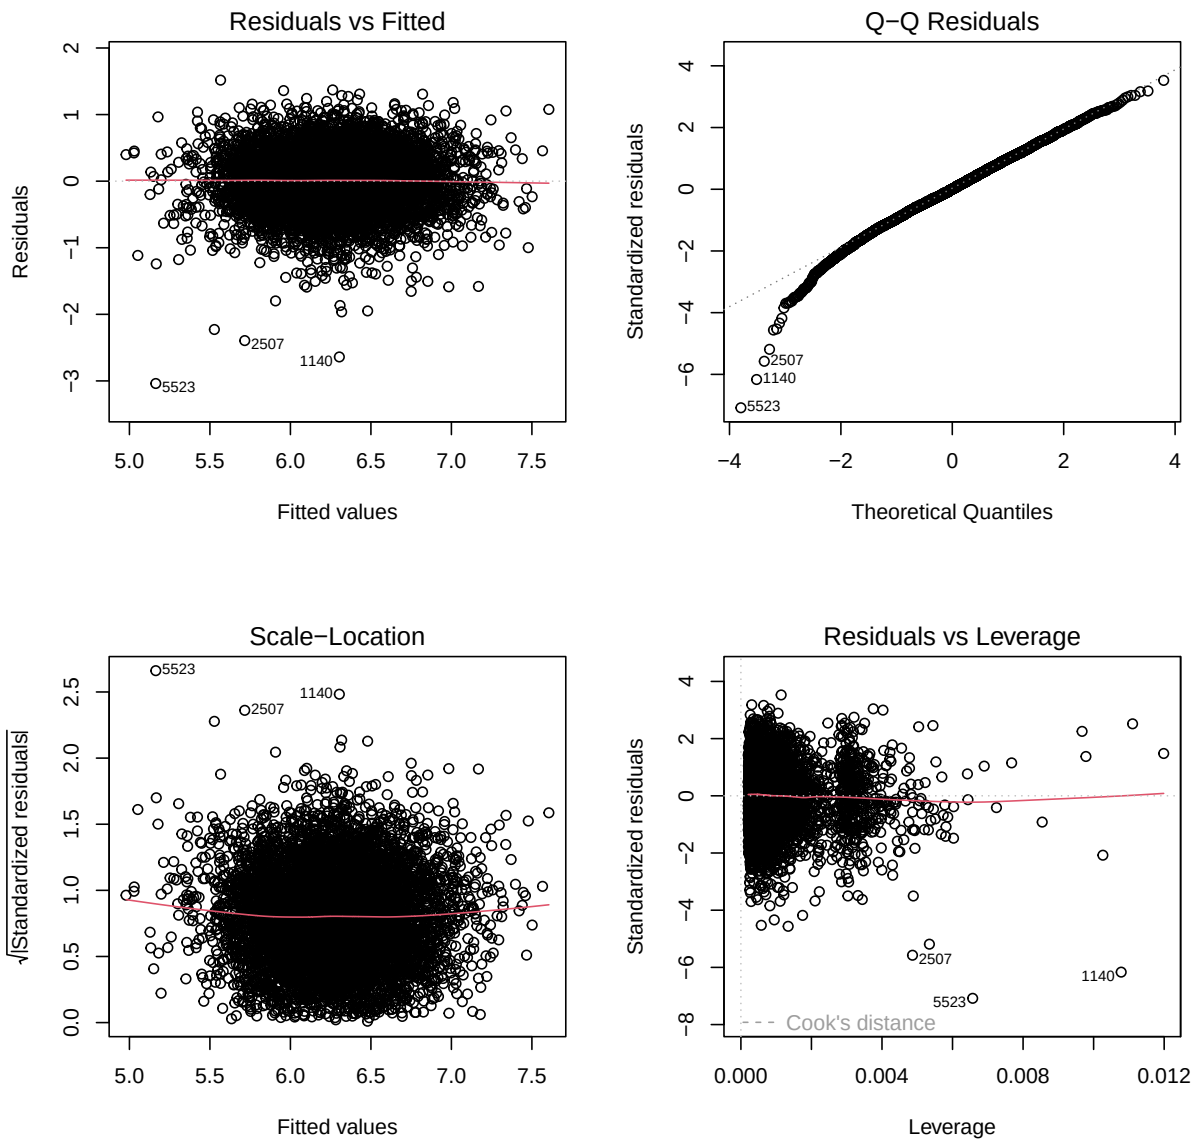

4.1 Análisis de los gráficos

1. **Residual vs Fitted**

En este gráfico podemos observar que la nube de puntos está bastante concentrada alrededor del 0. No se aprecia una curvatura clara, pero sí parece haber una ligera forma de banda y algo más de dispersión en algunas zonas.

Todo esto sugiere que la relación lineal no parece completamente absurda, es decir, no hay una señal clasísima de que el modelo esté mal por la no linealidad.

2. **Q-Q Residuals**

En este gráfico podemos observar que los puntos situados a la izquierda no siguen la diagonal, es decir, parece haber una desviación fuerte en los residuos más pequeños.

Mediante estas observaciones, tenemos indicios de que los residuos no siguen una distribución normal de forma estricta.

3. **Scale-Location**

Podemos observar, que en este gráfico la nube no es perfectamente horizontal, y se aprecia cierta variación en la aplitud de los residuos. Los casos más extremos vuelven a aparecer arriba.

Hay indicios leves heterocedasticidad, suficiente como para no dar por hecho que la varianza es constante.

4. **Residuals vs Leverage**

Observamos que la mayoría de observaciones tienen leverage bajo (acumulados a la izquierda) y hay unos pocos a la derecha con un leverage un poco más alto.

Esto sugiere que ciertos centros podían estar condicionando parcialmente la estimación del modelo y convendía revisar su impacto.

4.2 Evidencia visual

Para contrastar las observaciones

```r
# Comprobar la homocedasticidad
bptest(modelo_4)
```

```
    studentized Breusch-Pagan test

data:  modelo_4
BP = 261.88, df = 5, p-value < 2.2e-16
```

```r
coeftest(modelo_4, vcov = vcovHC(modelo_4, type="HC1"))
```

```
t test of coefficients:

                    Estimate Std. Error t value  Pr(>|t|)
(Intercept)       0.32792686 0.10131916  3.2366 0.0012156 **
average_bach      0.77299369 0.01338370 57.7564 < 2.2e-16 ***
standard_dev_bach 0.16836523 0.04943663  3.4057 0.0006638 ***
regime1           0.03740921 0.01252588  2.9866 0.0028315 **
regime2           0.07584026 0.03074924  2.4664 0.0136720 *
candidates        0.00111400 0.00018626  5.9811  2.33e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

El contraste de Breusch-Pagan muestra que la varianza de los errores no puede considerarse constate. Por tanto, el supuesto de homocedasticidad del modelo lineal clásico no se cumple.

La presencia de heterocedasticidad implica que los errores estándar clásicos del modelo lineal pueden no ser adecuados, afectando a la validez de los contrastes de significatividad habituales. Por esta razón, recalculamos los errores estándar mediante el estimador robusto HC1.

Tras esta corrección, todas las variables incluidas en el modelo continúan siendo estadísticamente significativas. En particular, la nota media de Bachillerato del centro sigue siendo la variable con mayor capacidad explicativa, con un coeficiente estimado de 0.773. Asimismo, la desviación típica de Bachillerato, el régimen del centro y el número de candidatos mantienen una asociación estadísticamente significativa con la nota media de la fase obligatoria de la PAU.

No podemos asumir que los residuos sigan una distribución normal estrícta dadas las claras desviaciones en el gráfico Q-Q anterior. Si la muestra hubiera sido menor, hubieramos utilizado el test de Shapiro-Wilk (`shapiro.test`), pero en R tiene un límite de muestra de 5000.